

# 文献综述：基于神经算子的托卡马克等离子体剖面拟合方法

2026 年 9 月 14 日

## 摘要

本综述围绕「用神经网络替代传统参数化拟合，从离散诊断测量点重构连续等离子体剖面 ( $T_e$ 、 $n_e$ 、 $T_i$ )」这一核心问题，梳理了三类相互关联的研究脉络：(1) 以  $\text{mtanh}$  为代表的传统剖面拟合范式及其局限；(2) 以 DeepONet 为核心的神经算子理论，以及 PointNet、Transformer、LSTM 等网络架构组件；(3) 深度学习在磁约束聚变诊断与剖面重建中的具体应用（RTCAKNN、NN-EFIT、EAST 快速平衡重建等）。在此基础上指出本文项目的定位：将 DeepONet 的分支-主干（branch-trunk）架构与物理约束损失相结合，从散射诊断点学习到剖面的算子映射，并嵌入 ONETWO 输运计算流程。

## 1 引言

磁约束聚变等离子体中，电子温度  $T_e$ 、电子密度  $n_e$  与离子温度  $T_i$  等径向剖面是输运分析、平衡重建与电流驱动建模的基础输入。这些剖面并非直接测量得到，而是由汤姆逊散射（TS）、反射计（Reflectometry）、X 射线晶体谱仪（XCS）等诊断系统在若干离散径向位置采样后，通过拟合与插值重建为连续曲线。剖面重建的精度与鲁棒性直接决定下游物理计算（如 ONETWO 输运求解、LHCD 电流驱动）的可靠性。

长期以来，剖面拟合依赖参数化模型与平滑插值。随着深度学习与神经算子理论的发展，一类「从离散测量到连续函数」的新范式正在兴起。本文从三条脉络梳理相关研究，并定位本文项目在其中的位置。

## 2 传统剖面拟合范式及其局限

### 2.1 $\text{mtanh}$ 台基参数化拟合

H 模等离子体的标志性特征是在边缘形成陡峭的输运垒（edge transport barrier, ETB），对应的温度与密度剖面呈现「芯部平坦 + 台基区陡峭下降」的形态。Groebner

等（2001）系统总结了 DIII-D 装置 H 模边缘物理的定量研究，确立了用**修正双曲正切函数（mtanh）**拟合台基剖面（pedestal profile）的标准方法。mtanh 函数以芯部高度、台基顶、台基宽度、斜坡位置等少数物理参数刻画台基形态，物理可解释性强，至今仍是主流剖面分析工具。

本项目中 `fitting_mtnh.py` 所实现的拟合链正是这一范式的典型代表： $T_e/n_e$  采用「芯部样条 + mtnh 台基 + 平滑过渡」， $T_i$  采用「mtnh +  $T_e$  台基边界约束」，并配合 IQR 迭代剔除异常点、PCHIP 保形单调插值等后处理。

## 2.2 参数化方法的固有局限

尽管 mtnh 范式物理清晰，但存在若干结构性局限：

1. **对异常点与噪声敏感**：拟合前需人工设置阈值、迭代剔除离群点，不同炮号/时间点需反复调参，主观性强。
2. **跨模式不鲁棒**：H 模与 L 模剖面形态差异显著，需要根据  $H_{98}$  阈值切换不同拟合分支，模式边界附近的分类错误会直接导致拟合失败。
3. **非物理振荡与负值**：样条/PCHIP 在数据稀疏或边缘外推时可能产生非物理振荡，甚至负值，进而导致 LHW 功率沉积积分中的  $\sqrt{\text{负值}} \rightarrow \text{NaN}$  问题（本项目代码中对此有专门的安全裁剪防护）。
4. **参数化表达能力受限**：固定函数形式的 mtnh 无法刻画偏离理想形态的剖面（如芯部非单调、双台基等）。

这些局限构成了用数据驱动方法替代/辅助参数化拟合的直接动机。

## 3 神经算子与 DeepONet 框架

### 3.1 从函数逼近到算子逼近

深度神经网络是连续函数的通用逼近器，但其经典形式学习的是「向量→向量」或「函数→标量」的映射。许多科学与工程问题——包括从离散诊断点重构连续剖面——本质上要求学习「函数→函数」的**算子映射**。Lu 等（2021）提出的**DeepONet（Deep Operator Network）**是基于算子普适逼近定理的实用实现，其核心是**双网络结构**：

- **分支网络（branch net）**：在固定的传感器位置  $\{x_1, \dots, x_m\}$  处编码输入函数，输出系数向量；
- **主干网络（trunk net）**：编码输出函数的位置坐标  $y$ ，输出一组基函数；
- **输出**：系数向量与基函数的点积，即  $G(u)(y) \approx \sum_k b_k(u) \cdot t_k(y)$ 。

这一「分支-主干点积」结构正是本项目 ProfileNet/LSTM/Transformer 三类架构共用的**SetEncoder + CoordDecoder**模式的直接理论来源：分支网络对应编码器（把散射点编码为固定维潜向量  $z$ ），主干网络对应 CoordDecoder（把目标  $\rho$  坐标映射为基函数），输出  $\text{Softplus}(z \cdot b(\rho))$ 。

DeepONet 的关键优势在于：输入函数在任意位置的传感器上采样、输出可在任意位置求值，天然适配「诊断点数量与位置可变」的剖面重构场景。

### 3.2 物理信息约束的引入

Wang 等（2021）提出**physics-informed DeepONet (PI-DeepONet)**，在 DeepONet 的数据拟合损失之外，利用自动微分施加偏微分方程的残差约束作为软惩罚，使预测结果满足底层物理规律。这一思想构成了本项目中**物理约束损失函数 (PhysicsConstrainedLoss)**的直接依据：

$$L = L_{\text{MSE}} + \lambda_1 L_{\text{mono}} + \lambda_2 L_{\text{bdy}} + \lambda_3 L_{\text{smooth}}$$

其中  $L_{\text{mono}}$  惩罚非单调段（对应剖面径向单调递减的物理预期）、 $L_{\text{bdy}}$  惩罚磁轴处非零导数（对应磁轴对称性）、 $L_{\text{smooth}}$  惩罚过大二阶导数（对应剖面光滑性）。这些约束并非来自 PDE 残差，而是来自剖面先验知识，本质上是 PI 思想在「无显式 PDE、但有强物理先验」问题上的自然推广。

### 3.3 神经算子概述与聚变应用

Karniadakis 等（2021）对物理信息机器学习进行了系统综述，奠定了 PINN/神经算子的统一框架。在聚变领域，Gopakumar 等（2024）将**Fourier Neural Operator (FNO)** 应用于 MAST 装置与 JOREK 模拟，展示了神经算子作为等离子体演化代理模型的潜力——相较于传统求解器获得约 6 个数量级的加速，且在归一化域内达到  $\approx 10^{-5}$  的 MSE。该工作证明了神经算子在磁约束聚变中的可行性，但关注的是时空演化的代理建模，而非本项目聚焦的稳态径向剖面重构。

## 4 网络架构组件

本项目的四类架构（ProfileNet、LSTM、CNN、Transformer）各自对应一类基础网络原语：

- **PointNet (Qi 等, 2017)**：首个直接消费点云的网络，通过对称函数（max pooling）保证对输入点集排列的**置换不变性**。这是本项目**ProfileNet** 的 **SetEncoder**的理论基础——诊断点的测量顺序无关紧要，恰好可用 PointNet 式的对称池化编码为潜向量。

- **Transformer** (Vaswani 等, 2017): 以多头自注意力替代循环与卷积, 能建模序列中任意位置间的全局依赖。本项目**Transformer 基线**采用 2 层、4 头的 TransformerEncoder 捕获散射点间的全局相关性, 与 LSTM 的递归建模形成对照。
- **LSTM** (Hochreiter & Schmidhuber, 1997): 长短期记忆网络通过门控机制建模序列长程依赖。本项目**BiLSTM 基线**以  $\rho$  排序后的输入编码径向序列结构。
- **CNN/ResNet**: 本项目**CNN-1D 基线**为纯残差卷积网络, 作为不采用 DeepONet 分支-主干结构的**独立对照组**, 用于验证「分支-主干点积」这一结构本身是否为性能增益的关键。

## 5 深度学习在聚变诊断与剖面重建中的应用

### 5.1 实时动力学剖面重建

Shousha 等 (2024) 提出的**RTCAKENN**是与本项目最直接相关的工作。该模型用机器学习近似 CAKE (一致自动动力学平衡重建) 的输出, 实时重构压力、反  $q$ 、环向电流密度、电子温度/密度、碳杂质温度与旋转等 7 条剖面, 并已在 DIII-D 等离子体控制系统 (PCS) 中部署。其架构采用「MLP 编码标量 + 1D 卷积编码剖面输入  $\rightarrow$  MLP 潜特征提取  $\rightarrow$  上采样 + 卷积解码」的编码器-解码器结构, 且通过 dropout 训练获得在缺失 TS 或 CXRS 数据时的鲁棒性。

本项目与 RTCAKENN 的目标 (从诊断测量重构剖面) 高度一致, 但存在三点差异: (1) 本项目直接学习「散射点 $\rightarrow$ 剖面」的算子映射 (DeepONet 式), 而 RTCAKENN 采用固定网格的卷积编码; (2) 本项目显式引入物理约束损失, 而非纯数据驱动; (3) 本项目针对 EAST 装置并嵌入 ONETWO/LHCD 输运流程, RTCAKENN 面向 DIII-D 实时控制。

### 5.2 平衡重建的神经网络代理

Sun 等 (2024) 训练多层感知机 (MLP) 作为 DIII-D 动力学 EFIT 的代理模型, 系统研究了不同诊断输入 (仅磁测量 vs. 加入压强/电流剖面等) 对重构精度的影响, 发现仅磁测量的模型已能输出较准确的动力学剖面。Lu 等 (2023, arXiv:2305.12098) 在 EAST 上发展了基于深度学习的快速平衡重建方法, 从磁测量预测 EFIT 极向磁通, 并自动优化网络超参数, 达到离线 EFIT 的空间分辨率同时满足实时控制的时间约束。

这些工作表明, 深度学习替代传统数值/参数化求解器已成为聚变诊断与平衡分析的重要趋势, 但其重点在平衡 (磁通/压强/电流) 而非本项目聚焦的  $T_e/n_e/T_i$  剖面拟合与 LHCD 输运。

### 5.3 EAST 诊断基础

Zang 等（2011）报道了 EAST 装置升级的多脉冲激光、多点汤姆逊散射（TS）诊断系统，是本项目  $T_e$  剖面训练数据来源（TS EAST）的物理基础。本项目的数据集覆盖 161 炮、约 3200 个样本， $T_e$  来自 TS， $n_e$  来自反射计， $T_i$  来自 XCS，正是建立在这些 EAST 诊断系统之上的。

## 6 输运建模与 LHCD 背景

剖面拟合的最终目的是为输运与电流驱动计算提供输入。本项目将拟合剖面接入 ONETWO 输运代码，并计算低杂波电流驱动（LHCD）。相关的集成建模框架（如 OMFIT, Meneghini 等, 2015）与 LHCD 物理（EAST 低杂波电流驱动实验与参数衰变不稳定性研究）构成了本项目下游应用的方法学背景。与上述神经算子/实时重建文献相比，本项目的特色在于：不仅关注剖面的拟合精度，更通过 `compare_profiles.py` 等工具评估不同拟合方法对下游 LHW 电流驱动剖面的实际影响，将「拟合精度的改善」与「物理计算结果的改善」直接关联。

## 7 总结：本文项目的定位

综合上述三条脉络，本文项目的创新点可归纳为：

1. **方法论交叉：**将 DeepONet 的「分支-主干」算子学习范式与物理约束损失（PI 思想的推广）相结合，用于托卡马克  $T_e/n_e/T_i$  剖面的数据驱动重构，替代 `mtanh+spline` 参数化拟合链。
2. **系统化架构对比：**在同一 DeepONet 框架下实现 SetEncoder（PointNet 式）、BiLSTM、TransformerEncoder 三种编码器，并以纯 ResNet CNN 作为非 DeepONet 对照组，定量回答「分支-主干点积」结构是否为性能关键。
3. **物理约束的显式编码：**以单调性、磁轴对称性、光滑性三条剖面先验作为软惩罚，验证物理先验对数据驱动拟合的增益（消融实验）。
4. **下游闭环验证：**将拟合剖面接入 ONETWO 输运流程与 LHCD 计算，评估不同拟合方法对电流驱动剖面的实际影响，突破「只比拟合精度、不比物理后果」的局限。

现有文献分别覆盖了神经算子理论（DeepONet/FNO）、物理信息约束（PINN/PI-DeepONet）、聚变剖面重建（RTCAKNN/NN-EFIT）等单个维度，但将三者系统结合、并以四种架构对照 + 物理约束消融 + 下游 LHCD 闭环验证的方式作用于 EAST 实测数据的完整研究尚属空白。本文正是对这一空白的填补。

## 参考文献（高相关性文献列表）

以下为与本文项目相关性最高的文献，按主题分组：

### A. 神经算子与物理信息学习（方法核心）

- [1] Lu L, Jin P, Karniadakis G E. DeepONet: Learning nonlinear operators for identifying differential equations based on the universal approximation theorem of operators. Nature Machine Intelligence, 2021.
- [2] Wang S, Wang H, Perdikaris P. Learning the solution operator of parametric PDEs with physics-informed DeepONets. arXiv:2103.10974, 2021.
- [3] Karniadakis G E, et al. Physics-informed machine learning. Nature Reviews Physics, 2021.
- [4] Gopakumar V, et al. Plasma surrogate modelling using Fourier Neural Operators. arXiv:2311.05967, 2024.

### B. 网络架构基础（组件）

- [1] Qi C R, et al. PointNet: Deep learning on point sets for 3D classification and segmentation. CVPR, 2017.
- [2] Vaswani A, et al. Attention is all you need. NeurIPS, 2017.
- [3] Hochreiter S, Schmidhuber J. Long short-term memory. Neural Computation, 1997.

### C. 剖面拟合与聚变 ML 应用（领域应用）

- [1] Groebner R J, et al. Progress in quantifying the edge physics of the H-mode regime in DIII-D. Nucl. Fusion 41, 1789 (2001).
- [2] Shousha R, et al. Machine learning-based real-time kinetic profile reconstruction in DIII-D. Nucl. Fusion 64, 026006 (2024).
- [3] Sun X, et al. Impact of various DIII-D diagnostics on the accuracy of neural network surrogates for kinetic EFIT reconstructions. Nucl. Fusion 64, 086065 (2024).
- [4] Lu J, Hu Y, Xiang N, Sun Y. Fast equilibrium reconstruction by deep learning on EAST tokamak. arXiv:2305.12098, 2023.

### D. EAST 装置与输运建模（背景）

- [1] Zang Q, et al. Upgraded multipulse laser and multipoint Thomson scattering diagnostics on EAST. Rev. Sci. Instrum. 82, 063502 (2011).

- [2] Meneghini O, et al. Integrated modeling applications for tokamak experiments with OMFIT. Nucl. Fusion 55, 083008 (2015).